

PREDICTIVE MAINTENANCE

설비 고장 예측 데이터 분석

AI4I 2020 Predictive Maintenance Dataset

github.com/Toquno-sayrin/smart-factory-predictive-maintenance

6조 · 서원준 · 최유성 · 정예림

팀 구성

Members & Roles

01

서원준

EDA

EDA · 전처리 · 데이터 제공

02

최유성

UI 구현

시각화 · 화면 구성

03

정예림

데이터 분석

ML 모델 학습 및 지표 검증

데이터 출처

UCI Machine Learning Repository

SOURCE



AI4I 2020 예측 유지보수 데이터 세트

2020년 8월 29일 에 기부되었습니다 .

AI4I 2020 예측 유지보수 데이터셋은 산업 현장에서 접하는 실제 예측 유지보수 데이터를 반영한 합성 데이터셋입니다.

데이터셋 특성 다변량, 시계열	주제 분야 컴퓨터 과학	관련 작업 분류, 회귀, 인과관계 발견
기능 유형 진짜	# 인스턴스 10000	# 특징 6

데이터셋 정보

추가 정보
실제 예측 유지보수 데이터 세트는 일반적으로 얻기 어렵고 특히 공개하기 어렵기 때문에, 본 연구에서는 업계에서 접하는 실제 예측 유지보수를 최대한 반영한 합성 데이터 세트를 제시하고 제공합니다.
...
더 보기 

결측값이 있습니까?
아니요

 다운로드 (509.9KB)

 파이썬에서 가져오기

인용문

” 1 인용
👁 조회수 136,845 회

DOI
10.24432/C5HS5C

특허
이 데이터 세트는 [크리에이티브 커먼즈 저작자 표시 4.0 국제 \(CC BY 4.0\)](#) 라이선스에 따라 사용이 허가되었습니다.

이를 통해 적절한 출처를 명시하는 조건 하에 데이터 세트를 모든 목적에 맞게 공유하고 활용할 수 있습니다.

밀링 설비 센서 데이터

- 금속을 회전 공구로 깎는 밀링 가공 설비에서 수집된 센서 기록
- 온도 · 회전속도 · 토크 · 공구마모를 실시간 측정
- 고장이 나기 전에 미리 잡아내는 것이 목표

데이터 소개

DATA

AI4I 2020 Predictive Maintenance Dataset

10,000

행 (데이터 수)

14

열 (컬럼 수)

339

고장 건수

3.39%

고장 비율

입력 변수

- 공기온도 [K] · 공정온도 [K]
- 회전속도 [rpm] · 토크 [Nm]
- 공구마모 [min] · 제품등급 (H/M/L)

정답 변수

- Machine failure (0 / 1)
- 0 → normal 9,661건
- 1 → fail 339건

EDA 전체 순서

Exploratory Data Analysis

1

기술통계

전체 윤곽과 자료형 파악
info() · describe()

2

단변량 분석

변수 하나씩 분포 확인
히스토그램 · 박스플롯

3

다변량 분석

여러 변수의 관계 파악
상관행렬 · 산점도

1. 기술통계

결측값 및 자료형 파악

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 14 columns):
#   Column                                Non-Null Count  Dtype  
---  --
0   UDI                                    10000 non-null  int64  
1   Product ID                           10000 non-null  object  
2   Type                                  10000 non-null  object  
3   Air temperature [K]                  10000 non-null  float64 
4   Process temperature [K]              10000 non-null  float64 
5   Rotational speed [rpm]                10000 non-null  int64  
6   Torque [Nm]                          10000 non-null  float64 
7   Tool wear [min]                      10000 non-null  int64  
8   Machine failure                      10000 non-null  int64  
9   TWF                                  10000 non-null  int64  
10  HDF                                  10000 non-null  int64  
11  PWF                                  10000 non-null  int64  
12  OSF                                  10000 non-null  int64  
13  RNF                                  10000 non-null  int64  
dtypes: float64(3), int64(9), object(2)
```

	UDI	Product ID	Type	Air_temperature	Process_temperature	Rotational_speed	Torque	Tool_wear	Machine failure	TWF	HDF	PWF	OSF	RNF
0	1	M14860	M	298.1	308.6	1551	42.8	0	0	0	0	0	0	0
1	2	L47181	L	298.2	308.7	1408	46.3	3	0	0	0	0	0	0
2	3	L47182	L	298.1	308.5	1498	49.4	5	0	0	0	0	0	0
3	4	L47183	L	298.2	308.6	1433	39.5	7	0	0	0	0	0	0
4	5	L47184	L	298.2	308.7	1408	40.0	9	0	0	0	0	0	0

컬럼 성격 구분

- 식별자 — UDI(일련번호), Product ID(제품번호)
- 범주형 — Type 하나뿐 (제품등급 H/M/L)
- 연속형 센서값 — 공기온도, 공정온도, 회전속도, 토크, 공구마모

결측값 0건 · 중복행 0건 — 별도 처리 불필요

1. 기술통계

변수별 스케일 확인

	UDI	Air temperature [K]	Process temperature [K]	\	
count	10000.00000	10000.000000	10000.000000		
mean	5000.50000	300.004930	310.005560		
std	2886.89568	2.000259	1.483734		
min	1.00000	295.300000	305.700000		
25%	2500.75000	298.300000	308.800000		
50%	5000.50000	300.100000	310.100000		
75%	7500.25000	301.500000	311.100000		
max	10000.00000	304.500000	313.800000		

	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]	Machine failure	\
count	10000.000000	10000.000000	10000.000000	10000.000000	
mean	1538.776100	39.986910	107.951000	0.033900	
std	179.284096	9.968934	63.654147	0.180981	
min	1168.000000	3.800000	0.000000	0.000000	
25%	1423.000000	33.200000	53.000000	0.000000	
50%	1503.000000	40.100000	108.000000	0.000000	
75%	1612.000000	46.800000	162.000000	0.000000	
max	2886.000000	76.600000	253.000000	1.000000	

	TWF	HDF	PWF	OSF	RNF
count	10000.000000	10000.000000	10000.000000	10000.000000	10000.000000
mean	0.004600	0.011500	0.009500	0.009800	0.00190
std	0.067671	0.106625	0.097009	0.098514	0.04355
min	0.000000	0.000000	0.000000	0.000000	0.00000
25%	0.000000	0.000000	0.000000	0.000000	0.00000
50%	0.000000	0.000000	0.000000	0.000000	0.00000
75%	0.000000	0.000000	0.000000	0.000000	0.00000
max	1.000000	1.000000	1.000000	1.000000	1.00000


확인된 점

- 회전속도(1168~2886)가 온도(295~314)보다 자릿수가 큼
- 거리 기반 모델을 쓰면 스케일링 필요
- TWF·HDF·PWF·OSF·RNF는 0/1 이진 컬럼
- 고장 평균 0.0339 → 심한 클래스 불균형

2. 단변량 분석

EDA 2

변수별 분포와 이상치



읽어낸 것

● 공기온도 · 공정온도

봉우리가 여러 개 — 측정값이 특정 지점에 몰림

● 회전속도

오른쪽으로 긴 꼬리 — 고속 운전 구간 존재

● 토크

정규분포에 가까움 — 변환 불필요


● 공구마모

균등하다가 200분에서 절단 — 교체 주기의 흔적

3. 다변량 분석

EDA 3

변수 간 상관관계



다중공선성 두 쌍

Air temp ↔ Process temp

0.88

Rotational speed ↔ Torque

-0.88

그래서 무엇이 문제인가

- 두 변수가 같은 정보를 중복해서 담고 있음
- 모델이 어느 쪽 때문인지 구분하지 못해 계수 해석이 어긋남
- 변수 중요도가 둘로 쪼개져 실제보다 낮게 보임

EDA 결과

탐색적 데이터 분석 정리

SUMMARY

01

데이터 품질

결측치 0건, 중복행 0건 — 별도 처리 불필요

02

이상치

토크 이상치 69건 중 90%가 고장 → 제거하지 않고 신호로 활용

03

상관관계

공기온도-공정온도 0.88, 회전속도-토크 -0.88

04

제품등급

고장률 L 3.92% > M 2.77% > H 2.09%

피처 엔지니어링

도메인 지식을 변수로

FEATURE

왜 만들었나

- 원본 변수와 고장의 상관이 최대 0.19에 그침
- 단일 변수로는 고장을 설명할 수 없음
- 상관계수가 아니라 설비 물리 관계에서 조합

핵심 물리량

power = 토크 × 각속도

속도-토크 다중공선성을 해소하면서 설비 출력이라는 의미를 얻음

temp_diff = 공정온도 - 대기온도

온도 다중공선성을 해소하면서 발열량을 직접 표현

컬럼	내용
power	토크 × 각속도 (W)
temp_diff	공정온도 - 대기온도 (K)
wear_torque	마모 × 토크
flag_heat	온도차 < 8.6 & 속도 < 1380
flag_power	출력 < 3500 or > 9000
flag_strain	wear_torque > 등급별 임계
flag_wear	마모 > 200분
risk_count	위 플래그 4개 합 (0~4)
power_dev	출력 중앙값과의 거리
wear_stage	마모 구간 0~4

파생변수 검증

물리 임계값과 실제 고장 라벨 대조

열 발산 고장	온도차 < 8.6K 그리고 회전속도 < 1380rpm	115 / 115
전력 고장	출력 < 3500W 또는 출력 > 9000W	95 / 95
과부하 고장	마모 × 토크 > 등급별 임계 (11000/12000/13000)	98 / 98

물리 조건만으로 실제 고장 라벨과 완전히 일치 — 예측 근거를 설명할 수 있는 구조

전처리

Preprocessing

PREP



결과 10,000행 × 9열 (입력 8개 + 정답 1개)

모델 채택 과정

MODEL

분류 모델 4종 비교

① 분류 (Classification) 모델 비교 결과

	모델	정확도	정밀도	재현율	F1-Score	AUC
	Random Forest	0.938	0.868	0.767	0.815	0.969
	XGBoost	0.946	0.826	0.884	0.854	0.977
	Logistic Regression	0.625	0.242	0.512	0.328	0.636
	SVM(RBF)	0.875	0.614	0.814	0.700	0.927

★ 최고 성능: XGBoost (정확도 0.946 / AUC 0.977)

최고 성능

XGBoost

정확도 0.946 · AUC 0.977

왜 XGBoost 인가

- 정형(테이블형) 센서 데이터에 강함
- 1만 행 규모의 소규모 데이터에 적합
- 트리 기반이라 변수 스케일에 덜 민감
- 결측치를 내부에서 자동 처리
- random_state=42 로 재현성 고정

학습 파이프라인

run_pipeline() 처리 순서

01

스케일링

`StandardScaler`

센서 5종 표준화

02

층화 분할

`stratify=y`

고장 3.4% 비율 유지

03

불균형 보정

`scale_pos_weight`

소수 클래스 가중

04

학습

`XGBClassifier.fit`

트리 부스팅

05

예측

`predict_proba`

확률값 산출

06

평가

`Recall` · `F1` · `AUC`

혼동행렬 · ROC

클래스 불균형 보정

KEY

scale_pos_weight

문제

정상 : 고장 = 28.5 : 1

해결

```
scale_pos_weight = neg / pos
```

- 고장 샘플을 틀렸을 때의 손실에 28.5배 가중
- 모델이 소수 클래스를 더 적극적으로 학습
- 기본 설정으로는 고장을 잘 잡아내지 못함

보정 효과

Recall

0.721 → 0.765

놓친 실제 고장

19건 → 16건

현장에서 3건의 예기치 못한 정지를 줄인 효과

임계값 실험

TUNING

decision_threshold 조정

predict() 대신 predict_proba() + 수동 임계값 비교

임계값을 decision_threshold 한 곳에서 통제할 수 있도록 설계 — 실험과 재현이 쉬워짐

threshold 0.3

- Recall 개선 없음
- 오탐(FP)만 증가
- F1 악화

threshold 0.5

채택

- Recall 유지
- 오탐 억제
- F1 최적

평가 지표 선택

무엇을 보고 좋은 모델이라 판단했나

Accuracy 98% 는 눈속임

전부 정상이라고 찍어도 96.6% — 고장이 3.4%뿐이라 정확도로는 변별이 안 됨

Recall · F1 · AUC 중심 평가

놓친 고장이 몇 건인가를 기준으로 판단 — 현장 손실과 직결되는 지표

Recall

실제 고장 중 잡아낸 비율

놓치면 설비 정지

F1-Score

정밀도와 재현율의 균형

오탐과 미탐을 함께

AUC

임계값과 무관한 분별력

모델 자체의 성능

교차검증

StratifiedKFold · F1

fold마다 비율 유지

사용된 주요 라이브러리 및 역할

- **tkinter / ttk (GUI Framework)**

버튼, 입력창, 표(Treeview) 같은 기본 위젯과 전체적인 데스크톱 애플리케이션의 레이아웃(GUI)을 구성하는데 사용

- **PIL (Pillow) (Image Processing)**


Tkinter가 기본적으로 지원하지 않는 일반 이미지 파일 (PNG, JPG 등)을 UI 화면에 매끄럽게 띄울 수 있도록 객체로 변환해 주는데 사용

- **matplotlib / seaborn**

데이터 분석(EDA) 및 모델 성능 검증 결과를 시각화한 차트를 Tkinter 대시보드 UI 내부에 임베딩하여 보여주는데 사용

UI 구현

RUNTIME



[Tab 1] 기준 데이터 분석

- 파일을 로드하고 원천 데이터의 상태를 1차적으로 확인하는 영역

load_file_action(): tkinter.filedialog를 띄워 로컬 CSV 파일을 선택하고, 백엔드(engine.load_data())로 전달합니다. 성공 시 각 탭의 렌더링 메서드를 연쇄적으로 호출

build_input_tab_content(): 전체 레코드 수, 고장 데이터 비율(Minority), 결측치 유무를 상단 KPI 카드로 띄웁니다. ttk.Treeview를 사용해 데이터프레임의 상위 레코드를 엑셀 표처럼 미리보기로 제공합니다

UI 구현

RUNTIME

현대오토에버 SW스쿨 - 스마트 팩토리 예지보전 시스템

HYUNDAI AUTOEVER | Smart Factory Predictive Maintenance System

제조 시 분석 대시보드

기본 데이터 분석

전처리 및 파이프라인

시각화(EDA) 및 의사결정

모델 평가

실시간 설비 관제 (모니터링)

1. 데이터 및 문제 정의

C:/Users/User/Desktop/

열기

타겟 변수 (Target)

Machine failure (0:정상/1:고장)

2. 학습/검증 설정

테스트 비율

0.2

교차검증

5-Fold

XGBoost 학습

전체 관제 스킴

도메인 물리 규칙 (AI4I Rules)

- TWf (공구 마모) : 마모도 > 200 min
- HDF (열열실물) : 온도차 < 8.6K & RPM < 1380
- PWF (전력이상) : 전력 < 3.0kW or > 9.0kW
- OSF (교구하) : 마모도 > 로크 한계 초과

[데이터 전처리 및 파이프라인 요약]

☒ 1. 결측치 검증: 0건

☒ 2. 식별자 컬럼: 있음 (학습 시 제외)

☒ 3. 범주형 컬럼: Type 컬럼 자동 인코딩

☒ 4. 수치형 컬럼: 학습 시 StandardScaler 적용

AI4I 2020 데이터셋 주요 컬럼 정의

컬럼명 (Feature)	데이터 타입	설명 및 단위
UDI	고유 번호 (Integer)	1부터 10,000까지의 데이터 순번 식별자
Product ID	문자열 (String)	품종 등급(L, M, H)과 제품 일련번호 조합
Type	범주형 (Categorical)	제품 품질 등급 (L: Low 50%, M: Medium 30%, H: High 20%)
Air temperature [K]	수치형 (Float)	대기 온도 (Kelvin 단위, 약 298K 내외)
Process temperature [K]	수치형 (Float)	공정 작동 온도 (대기 온도보다 항상 높음)
Rotational speed [rpm]	수치형 (Integer)	스핀들 회전 속도 (분당 회전수)
Torque [Nm]	수치형 (Float)	회전축에 걸리는 토크(힘) (Nm 단위)
Tool wear [min]	수치형 (Integer)	공구 마모 시간 (분 단위, 200분 이상 시 마모 한계)
Machine failure	타겟 (Binary)	설비 고장 여부 (0: 정상, 1: 고장 / 불균형 약 3.4%)

❗ 데이터 불균형: 경화도보다 '재현율(Recall)' 중점 모니터링

[Tab 2] 전처리 및 파이프라인


- 데이터가 모델에 들어가기 전 겪게 되는 변환 과정을 검증하고 명세서를 제공

build_preprocess_tab_content(): 결측치 처리 상태, 식별자(UDI, Product ID) 컬럼 제외 여부, 범주형 데이터(Type)의 원-핫 인코딩 상태를 조건문으로 검사하여 텍스트로 요약 출력

AI4I 2020 데이터셋의 각 센서 컬럼 단위와 설명을 명세서(Treeview) 형태로 하단에 렌더링

UI 구현

RUNTIME



[Tab 3] 시각화(EDA) 및 의사결정

- 공정 데이터의 통계적 특성과 도메인 지식을 시각적으로 연동하는 영역

build_eda_tab_content(): 센서별 최솟값, 평균치, 최댓값을 요약 표로 띄움

Matplotlib & Seaborn 임베딩: HDF, OSF 등 세부 고장 유형 빈도를 막대그래프(Bar)로, 핵심 센서 간 상관관계를 히트맵(Heatmap)으로 생성한 뒤 FigureCanvasTkAgg 객체를 통해 Tkinter 프레임 내부에 직접 부착



구현 그래프

히스토그램

변수별 분포

상관 히트맵

변수 간 관계

고장 유형 분포

TWF·HDF·PWF·OSF

판정 근거 카드

임계 조건 표시



[Tab 4] XGBoost 모델 평가


● 학습된 인공지능 모델의 신뢰성을 시각적으로 검증

start_training(): 좌측 패널에서 설정한 테스트 비율과 CV 값을 읽어 엔진의 run_pipeline()을 실행

build_evaluation_tab_content(res): 엔진으로부터 반환받은 평가 지표(res)를 화면에 뿌려줍니다. Accuracy, Recall 등의 수치를 상단 카드로 배치하고, 혼동 행렬(Confusion Matrix)과 ROC 곡선을 그래프로 렌더링

UI 구현

RUNTIME



[Tab 5] 실시간 설비 관제 (모니터링)

- 시스템의 핵심인 고장 징후 탐지 및 관리자 대응 가이드를 출력

build_predict_tab_content(): 좌측에 위험 징후 포착 설비 목록 리스트, 우측에 선택된 설비의 상세 센서 수치와 대응 가이드 텍스트를 띄울 빈 프레임을 구성합니다. 붉은색 경고 표시를 위해 `tree_predict.tag_configure('danger', ...)`를 미리 세팅

run_realtime_prediction(): 엔진의 테스트셋 데이터를 순회하며, 고장 확률이 임계치를 넘어 예측값(Prediction)이 1로 판정된 설비만 골라 좌측 위험 목록 Treeview에 추가

시연 영상